

Cómo funciona BenchMark-MOEAs

Documento técnico de funcionamiento. Explica qué sube el usuario, cómo se evalúa cada cosa, de dónde salen las tablas y las figuras, cómo se guarda el trabajo, y —al final— las restricciones actuales y lo que falta para los indicadores.

1. Qué hace la aplicación

La aplicación evalúa y visualiza aproximaciones al frente de Pareto (PFA) ya generadas por algoritmos evolutivos multiobjetivo (MOEAs). Compara varios MOEAs sobre varios problemas usando indicadores de calidad, y produce tablas y figuras listas para publicación.

La aplicación NO ejecuta MOEAs. No corre optimización. Parte de archivos .pof que ya contienen el resultado final de cada corrida.

El uso se organiza en cuatro pasos encadenados: cada paso se desbloquea una vez completado el anterior.

Paso 1 · Datos → Paso 2 · Indicadores → Paso 3 · Resultados → Paso 4 · Visualización

2. ¿Qué tiene que subir el usuario?

2.1 Los PFA

Un .zip con los archivos .pof , o los archivos .pof sueltos. Cada .pof es el frente final de una corrida: N filas (puntos) × m columnas (objetivos), separadas por espacios, sin encabezado. El nombre de cada archivo debe seguir una estructura exacta. La aplicación deduce toda la organización del experimento a partir del nombre; si no coincide con el patrón, el archivo se ignora.

Formato exacto que valida el nombre de un PFA:

{MOEA}_{MOP}_{m:02d}D_N{población}_R{corrida}.pof

Grupo	Regla	Ejemplo
moea	texto sin guion bajo	MOEAD
mop	texto sin guion bajo	DTLZ1
m	dígitos, seguidos de D	02D → m=2

Grupo	Regla	Ejemplo
n	dígitos, tras N	N11
corrida	dígitos, tras R	R01 → corrida 1

Ejemplo válido: **MOEAD_DTLZ1_02D_N11_R01.pof**

Validación adicional: al leer el archivo, la aplicación comprueba que el número de filas coincida con la N declarada en el nombre. Si no coincide, se rechaza.

2.2 Los frentes de referencia (según el indicador)

Los indicadores basados en distancia (IGD, IGD+, ϵ +, $\Delta\rho$, R2) necesitan el frente de Pareto verdadero del problema. La forma principal de proveerlos es que el usuario suba su propio conjunto de frentes de referencia, en un .zip con los archivos .pof dentro. Aunque la aplicación incluye un conjunto de frentes precargados por motivo de pruebas.

Formato exacto que valida un frente de referencia:

{MOP}_{mm}D.pof

Ejemplo Válido: **DTLZ2_03D.pof**.

3. ¿Cómo se evalúa cada cosa?

3.1 Agrupación por escenario

Un escenario es la combinación (MOP, m, N). Las corridas R01...R30 de un mismo escenario son repeticiones independientes. Dos poblaciones distintas del mismo problema (N11 y N25) son escenarios distintos y nunca se mezclan.

3.2 Indicadores de calidad

Indicador	Sentido	¿Requiere frente de referencia?	Estado
HV (Hypervolume)	maximizar	No	✓ Disponible
IGD	minimizar	Sí	✓ Disponible
IGD+	minimizar	Sí	✓ Disponible
ϵ+ (Epsilon aditivo)	minimizar	Sí	✓ Disponible

Indicador	Sentido	¿Requiere frente de referencia?	Estado
Δp (Delta p)	minimizar	Sí	✓ Disponible
R2	minimizar	Sí	⊖ Pendiente (falta parámetro)
Riesz s-energy	minimizar	No	⊖ Pendiente (falta parámetro)
SPD (Solow-Polasky)	maximizar	No	⊖ Pendiente (falta parámetro)

HV, IGD e IGD+ se calculan con pymoo; ϵ^+ y Δp con implementación propia. Cada indicador se calcula para cada corrida, y de los ~30 valores por escenario salen la media y la desviación estándar.

3.3 Punto de referencia del hipervolumen

El HV usa por defecto nadir + $0.1 \cdot (\text{nadir} - \text{ideal})$ (margen del 10 % del rango), calculado sobre la unión de todos los puntos del escenario. Esta fórmula es robusta a objetivos negativos; el ingenuo nadir $\times 1.1$ colapsaría el HV a cero en problemas con objetivos negativos (VNT2, VNT3).

4. Visualizaciones

4.1 Las tablas (Paso 3) — se basan en el script R del asesor

El procedimiento reproduce el método de createIndicatorTable.R:

- Media y desviación: equivalentes a mean()/sd() del R.
- Ranking: mismo criterio de orden que el order() del R (según el sentido del indicador).
- Rangos promedio: reproducen la salida *_avgRank.txt del R.
- Significancia: prueba de Mann-Whitney U, $\alpha = 0.05$, dirigida según el sentido (greater/less). Equivale al wilcox.test(d1, d2, alternative=...) sin paired=TRUE del R. Se compara al ganador contra cada uno de los demás.
- Formato LaTeX: replica el del R — ganador en gris oscuro (\cellcolor[gray]{0.5}), segundo en gris claro ({0.8}), rank como superíndice, \# en los vencidos con significancia, N/A cuando falta el dato.

Exportación: CSV, LaTeX y Markdown.

4.2 El Critical Differences plot

El CD plot es una extensión estándar de la literatura (Demšar 2006, post-hoc de Nemenyi) construida sobre esos rangos promedio que sí calcula el R. La distancia crítica se calcula así:

$$CD = q(\alpha, k) / \sqrt{2} \cdot \sqrt{(k(k+1) / 6N)}$$

con k = número de MOEAs y N = número de escenarios (q vía `scipy.stats.studentized_range`).

4.3 Las figuras y visualizaciones

Portadas desde los scripts de MOEA-visualization-main/ reproduciendo su lógica y estilo (colores, normalización, cmap), adaptadas a funciones headless (no leen archivos ni guardan a disco, tamaño ajustado a pantalla):

Figura	Script
Dispersión 2D	plot2D.py
Dispersión 3D	plot3D.py
Radar	radar.py
Heatmap	heatmap.py
Burbuja	bubble.py
Coordenadas paralelas	parallel_coord.py

Se grafica la corrida MEDIANA por indicador (el frente "típico"), no una arbitraria. Según el número de objetivos, la aplicación ofrece:

$m=2$ → dispersión, paralelas, radar, heatmap;

$m=3$ → las anteriores + burbuja;

$m>3$ → paralelas, radar, burbuja, heatmap.

Exportación: PNG, SVG, EPS y .tex (PGF).

5. Cómo se guarda el trabajo (persistencia SQLite)

La aplicación guarda un snapshot de sesión en un archivo .sqlite, para no re-evaluar desde cero. Lo que guarda depende del paso alcanzado:

- Guardado en Paso 1 → los PFA cargados y los frentes de referencia subidos.

- Guardado en Paso 2 → además, los indicadores seleccionados.
- Guardado en Paso 3 → además, los resultados ya evaluados (permite volver a elegir otros indicadores sin recalcular).

Esquema del .sqlite: tablas meta (nombre, paso, configuración, indicadores), pfa (los puntos como BLOB), frente_ref, resultado y omitido.

El guardado se entrega como archivo descargable y la carga es por subida de archivo, no por una ruta fija del servidor, porque en despliegues tipo Streamlit Cloud el disco es efímero.

Alcance actual: es un snapshot de sesión, no un registro reproducible. NO guarda los parámetros de cálculo (punto de referencia de HV, p de Δp , etc.). La reproducibilidad completa queda como trabajo futuro, porque algunos de esos parámetros aún no están definidos.

6. Restricciones actuales / Trabajo Futuro

6.1 Frentes de referencia

La aplicación incluye y fue probada solo con los siguientes frentes de referencia (en dimensiones $m = 2$ a 10):

DTLZ1, DTLZ2, DTLZ5, DTLZ7 · IMOP1–IMOP8 · WFG1, WFG2, WFG3 · VIE1, VIE2, VIE3

La aplicación puede aceptar cualquier otro problema: basta con subir su frente de referencia como .zip, con el nombre {MOP}_{mm}D.pof.

La arquitectura no está atada a un conjunto fijo de problemas.

Alias VNT - VIE: los problemas VNT2 y VNT3 no tienen archivo propio, usan los frentes VIE2 y VIE3. El mapeo ({"VNT2": "VIE2", "VNT3": "VIE3"}) se aplica automáticamente en la búsqueda de referencia.

6.2 Indicadores Actuales

- HV — punto de referencia sin confirmar. La política nadir + $0.1 \cdot \text{rango}$ es una decisión de ingeniería, falta determinar si el punto debe ser común a todo el experimento o por escenario, o si se prefiere un punto fijo por problema.
- Δp — parámetro p por defecto. Usa $p = 2$, falta determinar que sea la convención del grupo
- Costo de cómputo. IGD, IGD+, ϵ^+ y Δp se evalúan contra frentes de referencia de hasta $\sim 10\,000$ puntos; son costosos. HV y ϵ^+ son los más ágiles para iterar.

6.3 Indicadores Pendientes

Los tres indicadores bloqueados faltan determinar los parámetros en cada uno.

- R2 — falta el conjunto de vectores de peso (método de generación, cantidad) y la función de utilidad (Tchebycheff, weighted sum, PBI...).
- Riesz s-energy — falta el exponente s (¿fijo? ¿ $s = m - 1$?) y si se calcula sobre el frente normalizado.
- SPD (Solow-Polasky) — falta el parámetro θ , la métrica de distancia y si se normaliza.

6.4 Otras restricciones

Tablas LaTeX y `\cline`. El `.tex` de las tablas emite `\cline` (heredado del R). Con versiones recientes de `colortbl` (p. ej. MiKTeX 24.1) esto entra en conflicto con `\cellcolor` y no compila. Solución verificada: usar `\hhline`. La macro `\specialcell` no es estándar y debe definirse en el documento.

`.tex` de figuras requiere LaTeX. Usa el backend PGF, que invoca a `xelatex` para medir el texto. Sin LaTeX instalado, el botón se deshabilita solo (no falla). El `.tex` de las tablas, en cambio, no requiere LaTeX (es texto puro).

Convergencia y animación: no implementables con los datos actuales. Requieren el frente de cada corrida por generación; los `.pof` solo tienen el frente final. Quedan como trabajo futuro condicionado a que los MOEAs exporten snapshots por generación.

Visualizaciones de $m > 3$. Están implementadas y probadas, pero solo se ejercen con datos de 4+ objetivos, los datos disponibles hasta ahora son de $m = 2$ y 3.